

令和2年度 卒業論文

船舶の運航状況予測

Forecasting vessel operations



琉球大学工学部工学科知能情報コース

175755F 大城紳之亮

指導教員 當間愛晃

要 旨

近年、地球温暖化等の影響により台風や異常気象など天候の変化が激しく、これらの天候の変化は、船舶の運航に支障をきたす。船舶の欠航情報は出航当日にしか発表されないため、利用者が今後のスケジュールを計画する際に支障が出る可能性がある。本研究では、気象予報図、気象データ、欠航データを用いて、機械学習を適用して運航予測を行うことでスケジュール組み立ての一助となることを目指す。本研究で対象とした八重山諸島周辺の航路の欠航データと気象画像、気象値をそれぞれ別のデータセットとして構築し、教師データと特徴量を日付別にスライドさせ航路ごとにモデルを作成した。数値モデルの実験結果において、散布図を確認することでモデルの重要視している特徴を確認できた。画像モデルでの実験結果では、どのような画像がモデルに対して影響を与えていたか示した。また、特定の航路での精度評価から画像の周期性があることが明らかになった。今後の課題として、データセットの作成、モデルにおいて数値、画像の特徴を考慮する必要がある。

目 次

第 1 章 はじめに	1
1.1 背景と目的	1
1.2 関連研究	1
1.2.1 欠航判断においての研究事例	1
1.2.2 降雨レーダー画像を入力とした機械学習での予測においての研究事例	2
1.3 本研究の位置づけ	3
1.4 論文の構成	3
第 2 章 基礎概念	4
2.1 緒言	4
2.2 CNN	4
2.2.1 畳み込み層	4
2.2.2 プリーニング層	5
2.3 LightGBM	5
2.3.1 決定木	5
2.3.2 アンサンブル学習	6
2.3.3 勾配ブースティング	7
2.4 windy.com	7
2.5 安栄観光	7
2.6 予測精度の評価指標	7
第 3 章 提案手法	8
3.1 データ作成	8
3.1.1 安栄観光、windy.com からデータの取得	8
3.1.2 データセットの作成	8
3.2 運航状況の分類手法	10
3.2.1 学習モデル	10
第 4 章 実験	12
4.1 実験結果	12
4.1.1 数値データによる結果	12
4.1.2 画像データによる結果	12
4.2 考察	14

4.2.1	数値データの考察	14
4.2.2	画像データの考察	19
4.3	考察まとめ	25
第5章	結論	26
5.1	まとめ	26
5.2	今後の課題	26

図 目 次

1.1	1時間後先の降雨予測比較 [3]	2
1.2	CNN モデルの詳細 [4]	2
2.1	CNN の例 [13]	4
2.2	畠み込み層の出力例	5
2.3	プーリング層の出力例	5
2.4	決定木の例	6
2.5	アンサンブルの例	6
3.1	安栄観光 [6] の航路図	9
3.2	安栄観光 [6] の航路便運行状況	9
3.3	数値データの作成例	10
3.4	風速画像データの作成例	10
3.5	波高画像データの作成例	10
3.6	数値データの学習フロー	11
3.7	画像データの学習フロー	11
4.1	鳩間島航路 1 日前モデルの予測ラベル	15
4.2	鳩間島航路 9 日前モデルの予測ラベル	16
4.3	黒島航路当日モデルの予測ラベル別	17
4.4	黒島航路 1 日前モデルの予測ラベル別	18
4.5	黒島航路 1 日前モデルの真値ラベル別	19
4.6	波照間航路 1 日前モデルの混同行列	20
4.7	波照間航路 1 日前モデルの TP 画像例	21
4.8	波照間航路 1 日前モデルの FN 画像	21
4.9	波照間航路 1 日前モデルの FP 画像例	21
4.10	波照間航路 1 日前モデルの TN 画像例	21
4.11	FP 画像 1 日後の教師ラベル当日の画像	21
4.12	FN 画像 1 日後の教師ラベル当日の画像	21
4.13	波照間航路 2 日前モデルの混同行列	22
4.14	教師ラベル:運航 1	22
4.15	教師ラベル:運航 2	22
4.16	鳩間島航路当日モデルの混同行列	23

4.17 島間航路当日モデルの TP 画像例	23
4.18 島間航路当日モデルの FN 画像	23
4.19 島間航路当日モデルの FP 画像例	23
4.20 島間航路当日モデルの TN 画像例	23
4.21 教師ラベル:欠航	24
4.22 教師ラベル:運航	24
4.23 波照間航路 1 日前モデルの混同行列	24
4.24 波照間航路 2 日前モデルの混同行列	24

表 目 次

4.1	鳩間島航路-鳩間発	12
4.2	黒島航路-黒島発	12
4.3	波高レイヤー (波照間航路-波照発)	13
4.4	波高レイヤー (鳩間島航路-鳩間発)	13
4.5	波高レイヤー (竹富航路-竹富発)	13
4.6	風速レイヤー (波照間航路-波照発)	14
4.7	風速レイヤー (西表上原航路-西表上原発)	14
4.8	風速レイヤー (竹富航路-竹富発)	14

第1章 はじめに

1.1 背景と目的

近年、地球温暖化等の影響で台風や異常気象など天候の変化が激しい [1]。これらの天候変化は船舶の運航状況に支障をきたす。運航状況への支障として、船舶利用者が利用したいときに運航できない場合や貨物を運ぶ際に予定通りに運ぶことができないことがある。なかでも、旅客船に考えられる被害として、突然の欠航により船舶利用者の予定に支障が出る可能性がある。それにより経済的損失が発生する問題があると考えられる。船舶の運航を決定づける権限を持つのは船長であり、自身の経験に基づき気象通報、水路通報その他の航海に必要な情報を参考にすることで運航当日に決定している [8]。筆者は当日にしか公表されない船舶の運航状況を数日前に予測することで観光客や船舶の利用者のスケジュール組立ての一助を目指す。関連研究として沿岸波浪および、船体運動データを用いたシミュレーションによる新たな欠航判断基準を提供するものがある [2]。この研究では船体運動などのデータが必要不可欠であり、そのデータを取得するのは簡単ではないため、データ取得の容易な気象状況の値、あるいは予報図から船舶の欠航を予測したいと考えた。本研究では機械学習を用い、過去の欠航データ、気象データを活用し数日先までの欠航を予測することを目的とし実験を行う。

1.2 関連研究

1.2.1 欠航判断においての研究事例

笛 [2] らは運航判断において航海中の波浪の角度、周期が反映された船体運動にて評価すべきと考えている。そのため台風接近時のフェリーを検証対象とし船体運動データを観測した。また沿岸波浪(ナウファス)[5]と観測データをもとに船体運動のシミュレーションを実施し、検証した。これらの結果からフェリー欠航の新たな判断基準を提案するための基礎的研究を行った。

問題点として船体運動の縦揺れの再現結果が実測値よりも過小評価していることが挙げられる。シミュレーションの再現結果では船体の実際の有義振幅が 6.76° であるのに対し計算結果では 2.61° と半分以下の値が output されている。有義振幅とは、ある地点で観測された連続値のデータの大きい方から全体の $1/3$ の個数を平均して計算した振幅となる。また、シミュレーションに使用するデータが船体を観測して得られるデータのため、様々なフェリー航路への応用が難しく、データの取得が容易でない。そのため本研究では、デー

タ取得が比較的容易である天気予報 web サイトな windy[7] や運航状況を確認できる安栄観光 [6]などのサイトを使用しデータを活用して欠航の予測を行う。

1.2.2 降雨レーダー画像を入力とした機械学習での予測においての研究事例

Jason[3] らはディープラーニング(CNN)をモデルとして入力に降雨レーダー画像を使用し、出力に数時間先の降雨レーダー画像を生成する CNN を構築し、降雨量を予測することを目的に研究を行った。これをナウキャスティングという。降雨レーダー画像は MRMS[11] と呼ばれる $1km \times 1km$ の解像度で 2 分毎に得られるシステムを使用する。MRMS から得られるの 2017 年 7 月から 2019 年 7 月の期間のデータを使用する。画像の教師ラベルを降雨量の閾値 0,0.1,1.0,2.5 以上の 4 つの離散範囲に量子化する。2018 年分のデータをトレーニングし、2017 年と 2019 年をテストデータとして検証を行った。

図 1.1 は左が入力画像で中央が 1 時間先の降雨予測、右が 1 時間先の実際の降雨となっている。より具体的なモデルの構築内容は図 1.2 となっており、CNN の U-Net を使用している。

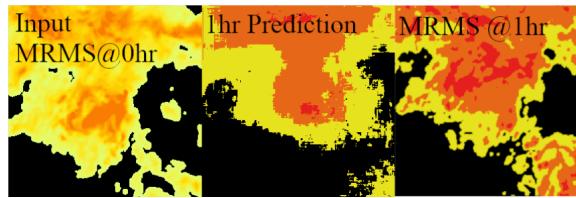


図 1.1: 1 時間後先の降雨予測比較 [3]

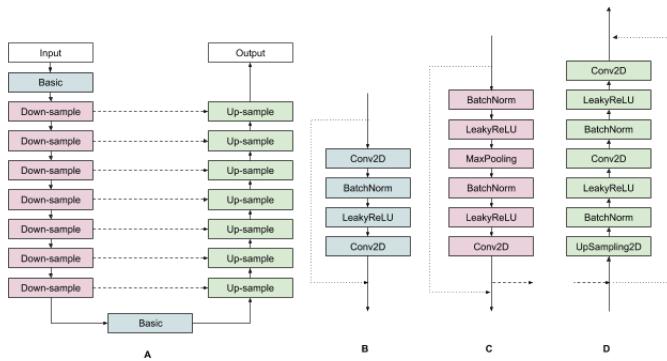


図 1.2: CNN モデルの詳細 [4]

Jason らの研究によるとこの CNN モデルを使用した 1 時間先の予測結果は既存のモデル optical flow[9]、persistence[10]、HRRR nowcasting[12] と比較して精度が良くなるという研究結果がある。しかし、5 時間先の予測の比較では HRRR が良いという結果となった。

結論としては 1 時間先という短時間予測においては CNN による画像から画像への予測変換モデルの有効性を示している。降水量の複雑な物理学をモデル化し、シミュレーションの時間がかかる手法をデータを入出力問題として扱うことで、1 時間先の予測は良好であることを示している。しかしながら、HRRR と機械学習の両方のアプローチの組み合わせが問題として残る。

Jason らの研究を踏まえて降雨レーダー画像を使用した機械学習の問題では CNN モデルがより良い精度を獲得できることがわかる。また、CNN を使用する理由の一つとして画像のデータの追加、交換が容易であることとしている。

本研究では天候データである画像は地球の任意の場所で取得できるということもあり、特定の地域だけでなく任意の航路の欠航予測を行うこともできる拡張性に着目し、採用する。また、降雨レーダー画像と本研究で使用するデータセットの画像、図 3.4、図 3.5 とは風、波と降雨のようにレイヤーが異なるだけなので CNN モデルが有効だと考える。本研究の入力データは画像だが出力データは運航、欠航の 2 値分類のため出力結果を 2 値のクラス分類にする必要がある。

1.3 本研究の位置づけ

本研究は船舶の運航状況を欠航か運航か分類する二値分類タスクである。使用するデータとしては運航か欠航であるかの二値の教師データ、そこに付随する特徴量として数値データ(風速や波の高さ等)または画像データの 2 種類がある。これらの 2 種類のデータを分けて学習モデルに学習させ違いを比較することで、本研究の船舶での予測を行う際の最適なデータを検討する一助を目指し、さらに数値だけでの予測よりも精度向上を望めないか検討する。また、数日先までの予測を数値を使用した予測と画像を使用した予測を行った場合との違いを比較、考察を行い、数値と画像との精度評価を実施する。

1.4 論文の構成

本論文は、以下の通りに構成されている。

第1章 はじめに

本研究の背景と目的について述べる。

第2章 基礎概念

提案手法に関することについて述べる。

第3章 提案手法

機械学習の実装とデータ作成に関するこについて述べる。

第4章 実験

実験と考察について述べる。

第5章 今後の課題

提案手法と検証に関する今後の課題を述べる。

第2章 基礎概念

2.1 緒言

船舶の運行状況予測をするにあたり、予測に使用した学習モデルや評価指標について述べる。

2.2 CNN

CNNとは畳み込みニューラルネットワークのことで畳み込み層やプーリング層などの層が積み重なったニューラルネットワークであり、Y. LeCun[13]らが最初に提唱した畳み込みニューラルネットワーク図2.1が有名である。画像を入力とした畳み込みニューラルネットワークの特徴的な層について説明する。

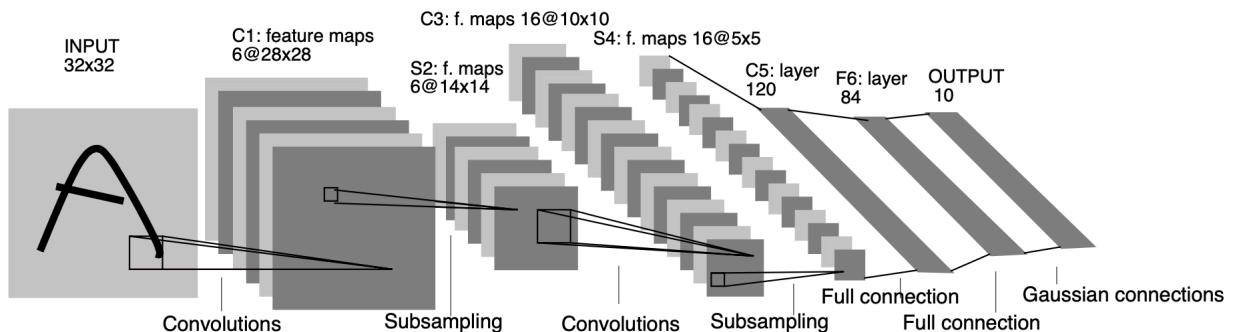


図 2.1: CNN の例 [13]

2.2.1 畳み込み層

入力画像を畳み込み層に入力し画像から特徴を図2.2にのように抽出する。図2.2では入力画像がカラー画像(RGB)の場合、入力に対してR、G、Bそれぞれのチャンネルに対して対応するフィルタを適用する。R、G、Bの入力に対してフィルタを重ね合わせ、合わせた部分の画素値に乗算を適用し合計値を算出、さらにR、G、Bの合計値により出力の画素値が決定し、その処理をスライドさせながら画像全体に対して行う。

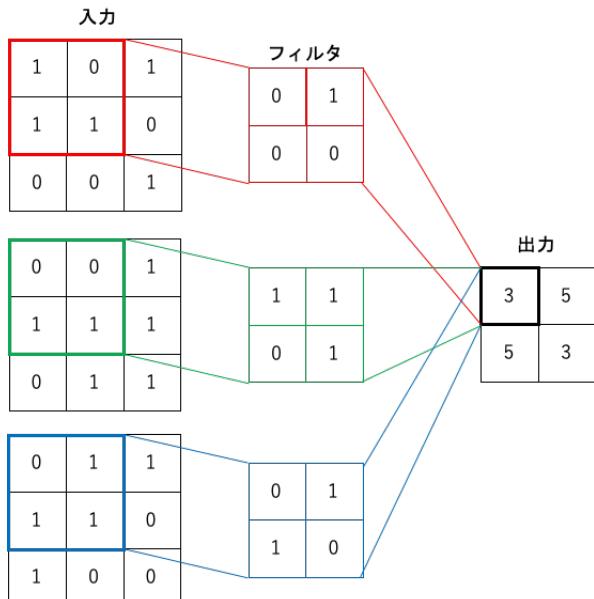


図 2.2: 置み込み層の出力例

2.2.2 プリーニング層

プリーニング層とは入力画像内の局所的な情報を集めることである。とくに Max Pooling の図 2.3 では入力に対して局所的な領域の最大値を出力する処理を行うことである。

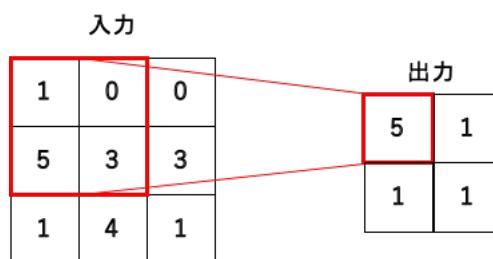


図 2.3: プリーニング層の出力例

2.3 LightGBM

LightGBM とは決定木アルゴリズムをベースにした勾配ブースティングの機械学習フレームワークである。LightGBM の特徴として決定木、アンサンブル学習、勾配ブースティングなどがある。それについて説明する。

2.3.1 決定木

LightGBM では決定木を基にしたアルゴリズムを使用している。決定木とは図 2.4 のように項目において閾値を決定し閾値により条件分岐させ木のように成長させて問題を解

くアルゴリズムである。

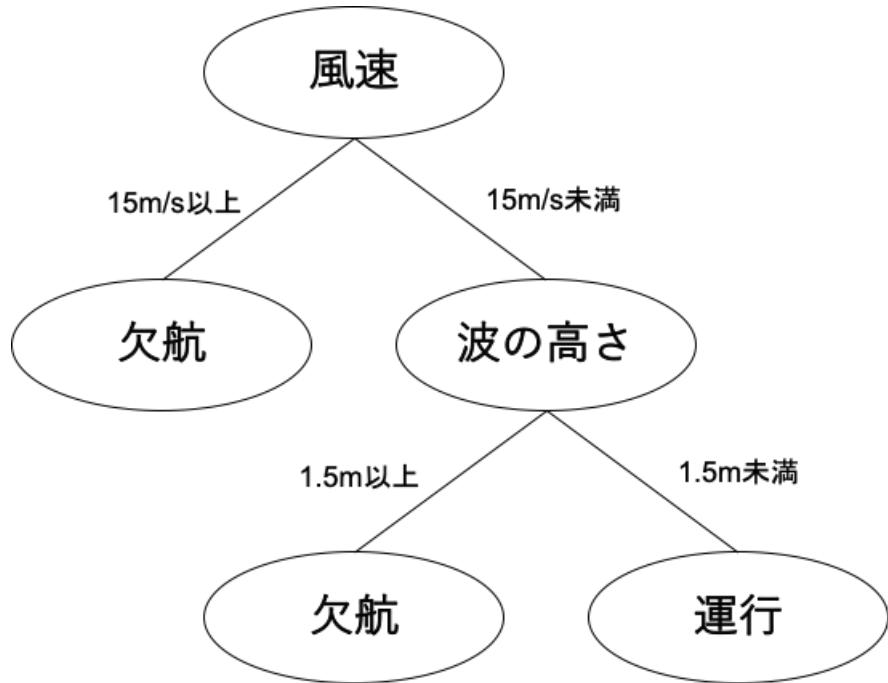


図 2.4: 決定木の例

2.3.2 アンサンブル学習

アンサンブル学習とは複数のモデルを学習させて1つの学習モデルを生み出す学種方法である。このようにすることで精度の低いモデルでも高精度な予測をすることができる。図2.5の例ではモデルの数を4つとしたときにそれぞれのモデルの予測結果の多数決をとることで最終的に100%の精度で予測することができる。

正解	モデル1	モデル2	モデル3	モデル4	予測
○	○	×	○	○	○
○	○	○	×	○	○
○	×	○	○	○	○
×	×	×	×	○	×

75% 75% 75% 75% 100%

図 2.5: アンサンブルの例

2.3.3 勾配ブースティング

勾配ブースティングはアンサンブル学習の手法のひとつである。ブースティングとはデータセットの中から一部のデータを用いてモデルを学習し評価を行う。その後の別モデルで前のモデルで誤った予測をしたデータを学習し評価を行いさらに次のモデルでも同じことを行うことでデータの誤差の学習を行う。最後に各モデルの多数決を行いモデルを組み合わせる。

2.4 windy.com

本研究に使用したデータを取得してきた web サイトである。このサイトは世界中の天気予報を可視化でき、リアルタイムの気象状況や気象値、数日先までの予報を閲覧することができる。レイヤー機能があり風速レイヤー、波高レイヤーや気温レイヤーなど様々なレイヤーを使用でき、レイヤーごとの特徴を視覚的に見ることができる [7]。

2.5 安栄觀光

本研究に使用した教師データを取得してきた web サイトである。このサイトでは主に石垣島から西表島への 7 つある航路の船舶運行状況を確認できる [6]。

2.6 予測精度の評価指標

本研究では上記で説明した学習モデルで入力を画像とする場合は CNN を採用し、数値を入力する場合は LightGBM を採用する。予報図(画像)、気象状況(数値)の比較を行うためそれぞれの予測精度を評価する必要がある。本研究の問題は二値分類問題であるので一般に正解率、適合率、再現率、F 値を使用して評価をすることが多い。そのため本研究でもこれらの評価指標を用いて評価を行なう。

第3章 提案手法

3.1 データ作成

本研究では八重山諸島の船舶航路を対象とし、安栄観光[6]とwindy.com[7]というwebサイトからデータを取得し、機械学習を用いて欠航予測を行うことを目的とする。

3.1.1 安栄観光、windy.com からデータの取得

安栄観光[6]の運行状況のページから波照間島航路、西表島上原航路、鳩間島航路、西表島大原航路、小浜島航路、竹富島航路、黒島航路の7つの運行状況データを使用する。運行状況データにはそれぞれの航路別で出港時間毎に通常運行、欠航の情報がある。それぞれの航路は図3.1となる。

windy.com[7]では地球の任意の地点を選択し、天気予報などの様々な情報を確認することができる。八重山諸島航路は鳥瞰すると西表島と石垣島間を行き来する運行航路であることから、運行航路の北側、南側の2地点からデータを取得する。2地点の風速、最大風速、最大風速の風向、波高、波の向き、うねり、うねりの向き、うねりの間隔の数値データを対象とする。このデータは当日の7時から17時まで2時間間隔で取得し、当日から7日先までは0時から21時まで3時間間隔で確認することができ、当日から8日、9日、10日の3日間は3時から21時までの6時間間隔で確認できるため、以上のデータを取得する。また、気象データとしてWebページのスクリーンショットを当日から9日先までは7時から17時までの2時間間隔で取得し10日先に関しては7時から11時までを取得する。windy.com[7]ではレイヤーで風速、波高等の情報が分かれているため、その2種類のレイヤーで画像データとして取得する。

風速、波高データを取得する理由として、対象の航路の欠航判断基準[8]に風速、波高、視程等の項目があるため、参考にデータの取得範囲を風速、波高等に設定した。

3.1.2 データセットの作成

安栄観光[6]から得た運行状況データを教師データラベルとして、それ以外のデータを特徴量として機械学習にデータを適用するために前処理を行う。本研究では数値データと画像データを取得しているため、別々のデータセットとしてデータを作成していく。前処理として取得した運行状況データは運行を0に、欠航を1の二値にエンコードする。画像データは画像を数値に変換するためにRGBの値にエンコードし 64×64 のサイズにリサ

イズする。

例として1便の運行状況データを図3.2の赤枠を1サンプルの教師データとする。特徴量は運行状況データの時間帯周辺で取得された風速、波高等データを合わせたものを数値データのデータセットでは図3.3のような例を1サンプルとする。画像データのデータセットでは風速、波高レイヤーでスクリーンショットを行った画像を特徴量とし図3.4、図3.5のように1サンプルとする。これらのサンプルデータの作成方法で数値、画像データを構築する。

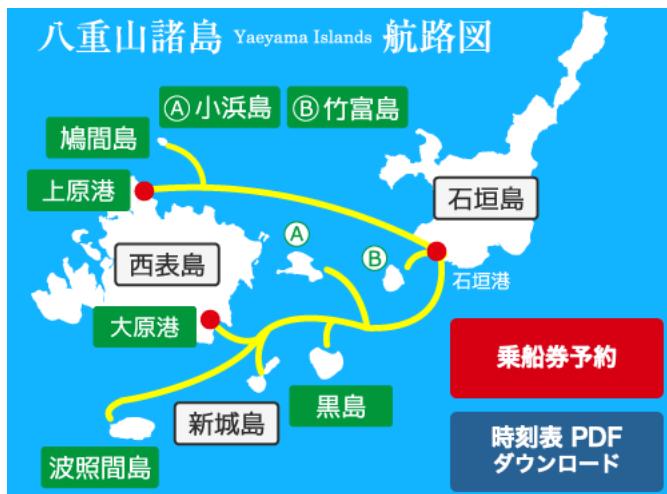


図 3.1: 安栄観光 [6] の航路図

竹富島航路			
石垣発		竹富発	
07 : 30	<input type="radio"/> 通常運航	07 : 50	<input type="radio"/> 通常運航
08:30	<input type="radio"/> 通常運航	08:50	<input type="radio"/> 通常運航
09:30	<input type="radio"/> 通常運航	09:50	<input type="radio"/> 通常運航
10:30	<input type="radio"/> 通常運航	10:50	<input type="radio"/> 通常運航
11:30	<input type="radio"/> 通常運航	11:50	<input type="radio"/> 通常運航
13:00	<input type="radio"/> 通常運航	13 : 20	<input type="radio"/> 通常運航
14:00	<input type="radio"/> 通常運航	14:20	<input type="radio"/> 通常運航
15:00	<input type="radio"/> 通常運航	15:20	<input type="radio"/> 通常運航
16:00	<input type="radio"/> 通常運航	16:20	<input type="radio"/> 通常運航
----	-	----	-
17 : 00	<input type="radio"/> 通常運航	17 : 20	<input type="radio"/> 通常運航
----	-	----	-
18:00	<input type="radio"/> 通常運航	18:20	<input type="radio"/> 通常運航

図 3.2: 安栄観光 [6] の航路便運行状況

9/10に取得できた教師データ		9/10/7:00に取得できたデータ	
07 : 50		風速	6
		最大風速	9
		最大風速の風向	154
		波高	0.6
		波の向き	99
		うねり	0.6
		うねりの間隔	8.8
		うねりの向き	105

教師データ	風速	最大風速	最大風速の風向	波高	波の向き	うねり	うねりの間隔	うねりの向き
通常運行	6	9	154	0.6	99	0.6	8.8	105

図 3.3: 数値データの作成例



図 3.4: 風速画像データの作成例

図 3.5: 波高画像データの作成例

3.2 運航状況の分類手法

本研究では教師あり学習の分類問題として機械学習モデルを適用する。数値データセットでは LightGBM を用い、画像データセットでは、CNN を使用する。

3.2.1 学習モデル

実験に使用したデータは大まかに 2020 年 8 月から 2021 年 1 月までの期間に取得できたものとなる。学習モデルは航路に特化させるために航路ごとにデータセットを分けて学習を行うことで 7 航路あるうちのそれぞれに出発港が 2 つあるため $7 \times 2 = 14$ 個のモデル

となる。さらに、データを教師データの当日から $9 = n$ 日前までの特徴量をスライドさせ当日のデータから当日の予測、 n 日前のデータから n 日後の予測を行うためモデルを分けた。モデルを分けて作成したためモデルの総数は $14 \times 10 = 140$ とし、数値データは図 3.6 となる。また画像データではさらに風速レイヤー、波高レイヤーで別々のデータセットのため $140 \times 2 = 280$ 個のモデルがあり、図 3.7 となる。

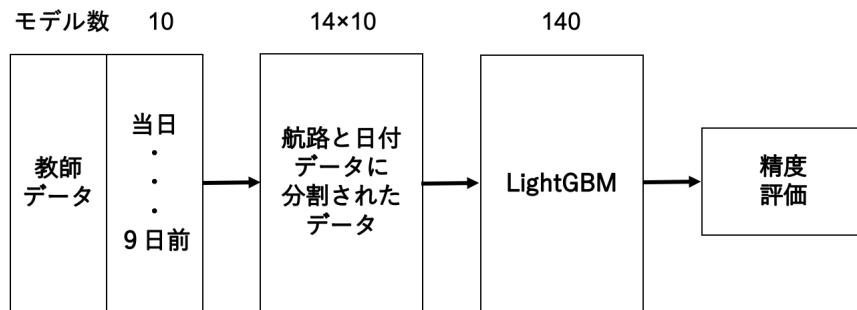


図 3.6: 数値データの学習フロー

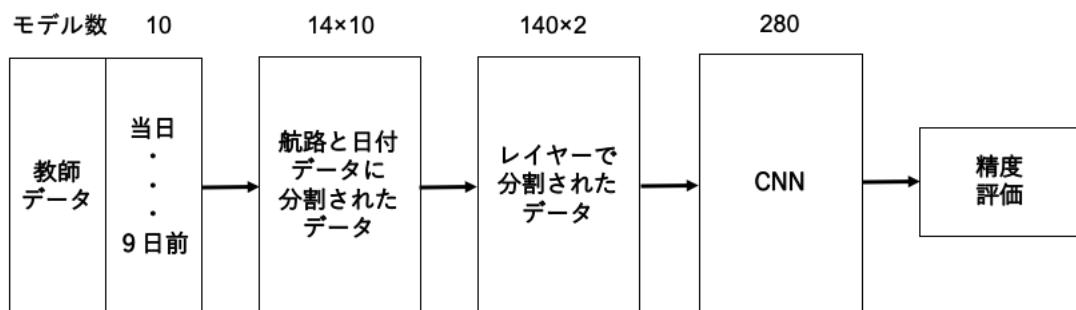


図 3.7: 画像データの学習フロー

第4章 実験

4.1 実験結果

4.1.1 数値データによる結果

数値データを用いた精度（正解率・適合率・再現率・F値）を表4.1、表4.2に示す。また、西表大原航路、小浜航路、竹富航路では欠航データが無く精度が100%となったので省く、波照間航路や西表上原航路は表4.1のような傾向と似ている結果となつたため省く。

表 4.1: 鳩間島航路-鳩間発

	正解率	適合率	再現率	F 値
当日	0.868	0.933	0.778	0.848
1日前	0.816	0.875	0.737	0.800
2日前	0.816	0.929	0.684	0.788
3日前	0.649	0.636	0.737	0.683
4日前	0.757	0.737	0.778	0.757
5日前	0.639	0.667	0.556	0.667
6日前	0.722	0.833	0.556	0.667
7日前	0.583	0.562	0.529	0.545
8日前	0.714	0.733	0.647	0.688
9日前	0.629	0.625	0.588	0.606

表 4.2: 黒島航路-黒島発

	正解率	適合率	再現率	F 値
当日	1.000	1.000	1.000	1.000
1日前	0.987	0.000	0.000	0.000
2日前	1.000	1.000	1.000	1.000
3日前	0.986	0.000	0.000	0.000
4日前	1.000	0.000	0.000	0.000
5日前	0.986	0.000	0.000	0.000
6日前	0.986	0.000	0.000	0.000
7日前	0.986	0.000	0.000	0.000
8日前	1.000	1.000	1.000	1.000
9日前	0.986	0.000	0.000	0.000

4.1.2 画像データによる結果

画像データの波高レイヤーデータを用いた精度（正解率・適合率・再現率・F値）を表4.3、表4.4、表4.5に示す。また、小浜島航路、黒島航路、西表大原航路は表4.5と同様の結果が出力されたため省く、西表上原航路は表4.4と傾向が似ているため省く。

表 4.3: 波高レイヤー(波照間航路-波照発)

	正解率	適合率	再現率	F 値
当日	0.796	0.643	0.643	0.643
1日前	0.833	0.857	0.462	0.600
2日前	0.723	0.000	0.000	0.000
3日前	0.723	0.000	0.000	0.000
4日前	0.756	0.000	0.000	0.000
5日前	0.778	0.000	0.000	0.000
6日前	0.773	0.000	0.000	0.000
7日前	0.773	0.000	0.000	0.000
8日前	0.773	0.000	0.000	0.000
9日前	0.767	0.000	0.000	0.000

表 4.4: 波高レイヤー(鳩間島航路-鳩間発)

	正解率	適合率	再現率	F 値
当日	0.882	0.929	0.812	0.867
1日前	0.818	0.917	0.688	0.786
2日前	0.727	0.818	0.562	0.667
3日前	0.562	0.545	0.400	0.462
4日前	0.594	0.538	0.500	0.519
5日前	0.645	0.615	0.571	0.593
6日前	0.613	0.600	0.429	0.500
7日前	0.581	0.545	0.429	0.480
8日前	0.700	0.647	0.786	0.710
9日前	0.667	0.667	0.571	0.615

表 4.5: 波高レイヤー(竹富航路-竹富発)

	正解率	適合率	再現率	F 値
当日	0.990	0.000	0.000	0.000
1日前	0.979	0.000	0.000	0.000
2日前	0.974	0.000	0.000	0.000
3日前	0.973	0.000	0.000	0.000
4日前	0.972	0.000	0.000	0.000
5日前	0.972	0.000	0.000	0.000
6日前	0.977	0.000	0.000	0.000
7日前	0.989	0.000	0.000	0.000
8日前	0.994	0.000	0.000	0.000
9日前	0.994	0.000	0.000	0.000

画像データの風速レイヤーデータを用いた精度（正解率・適合率・再現率・F 値）を表 4.6、表 4.7、表 4.8 に示す。また、小浜島航路、黒島航路、西表大原航路は表 4.7 と同様の結果が出力されたため省く、鳩間島航路は表 4.7 と傾向が似ているため省く。

表 4.6: 風速レイヤー(波照間航路-波照発)

	正解率	適合率	再現率	F 値
当日	0.776	0.579	0.786	0.667
1日前	0.812	0.750	0.462	0.571
2日前	0.729	0.000	0.000	0.000
3日前	0.723	0.000	0.000	0.000
4日前	0.756	0.000	0.000	0.000
5日前	0.778	0.000	0.000	0.000
6日前	0.773	0.000	0.000	0.000
7日前	0.773	0.000	0.000	0.000
8日前	0.750	0.000	0.000	0.000
9日前	0.767	0.000	0.000	0.000

表 4.7: 風速レイヤー(西表上原航路-西表上原発)

	正解率	適合率	再現率	F 値
当日	0.846	0.863	0.786	0.822
1日前	0.803	0.971	0.589	0.733
2日前	0.708	0.769	0.536	0.632
3日前	0.619	0.610	0.463	0.526
4日前	0.696	0.684	0.531	0.598
5日前	0.649	0.610	0.510	0.556
6日前	0.598	0.562	0.367	0.444
7日前	0.527	0.429	0.180	0.254
8日前	0.709	0.630	0.902	0.742
9日前	0.697	0.638	0.755	0.692

表 4.8: 風速レイヤー(竹富航路-竹富発)

	正解率	適合率	再現率	F 値
当日	0.990	0.000	0.000	0.000
1日前	0.979	0.000	0.000	0.000
2日前	0.974	0.000	0.000	0.000
3日前	0.973	0.000	0.000	0.000
4日前	0.978	0.000	0.000	0.000
5日前	0.989	1.000	0.600	0.750
6日前	0.978	0.000	0.000	0.000
7日前	0.989	0.000	0.000	0.000
8日前	0.994	0.000	0.000	0.000
9日前	0.994	0.000	0.000	0.000

4.2 考察

4.2.1 数値データの考察

表 4.1 の鳩間島航路-鳩間発 1 日前モデルにおけるテストデータの予測結果別に色分けをした散布図が図 4.1 になる。この図を見ると特徴量 wave_height の箇所で明確な色分けがおこなわれているのが確認でき、教師ラベルとの強い関係性を見ることができる。この結果から 1 日前モデルが wave_height を重要な特徴量として処理していると考えられる。そこで、9 日前モデルの散布図 4.2 を見ると各特徴量と教師データとの結びつきが弱くなっていることが確認できる。そのため 9 日前モデルでは表 4.1 で示されているように予測精

度が悪くなっていることが説明できる。これはデータセット作成する際、特徴量と教師ラベルを9日間ずらして作成しているため、1日前と比較して特徴量が運航や欠航を説明するための情報が減少していると考えられる。

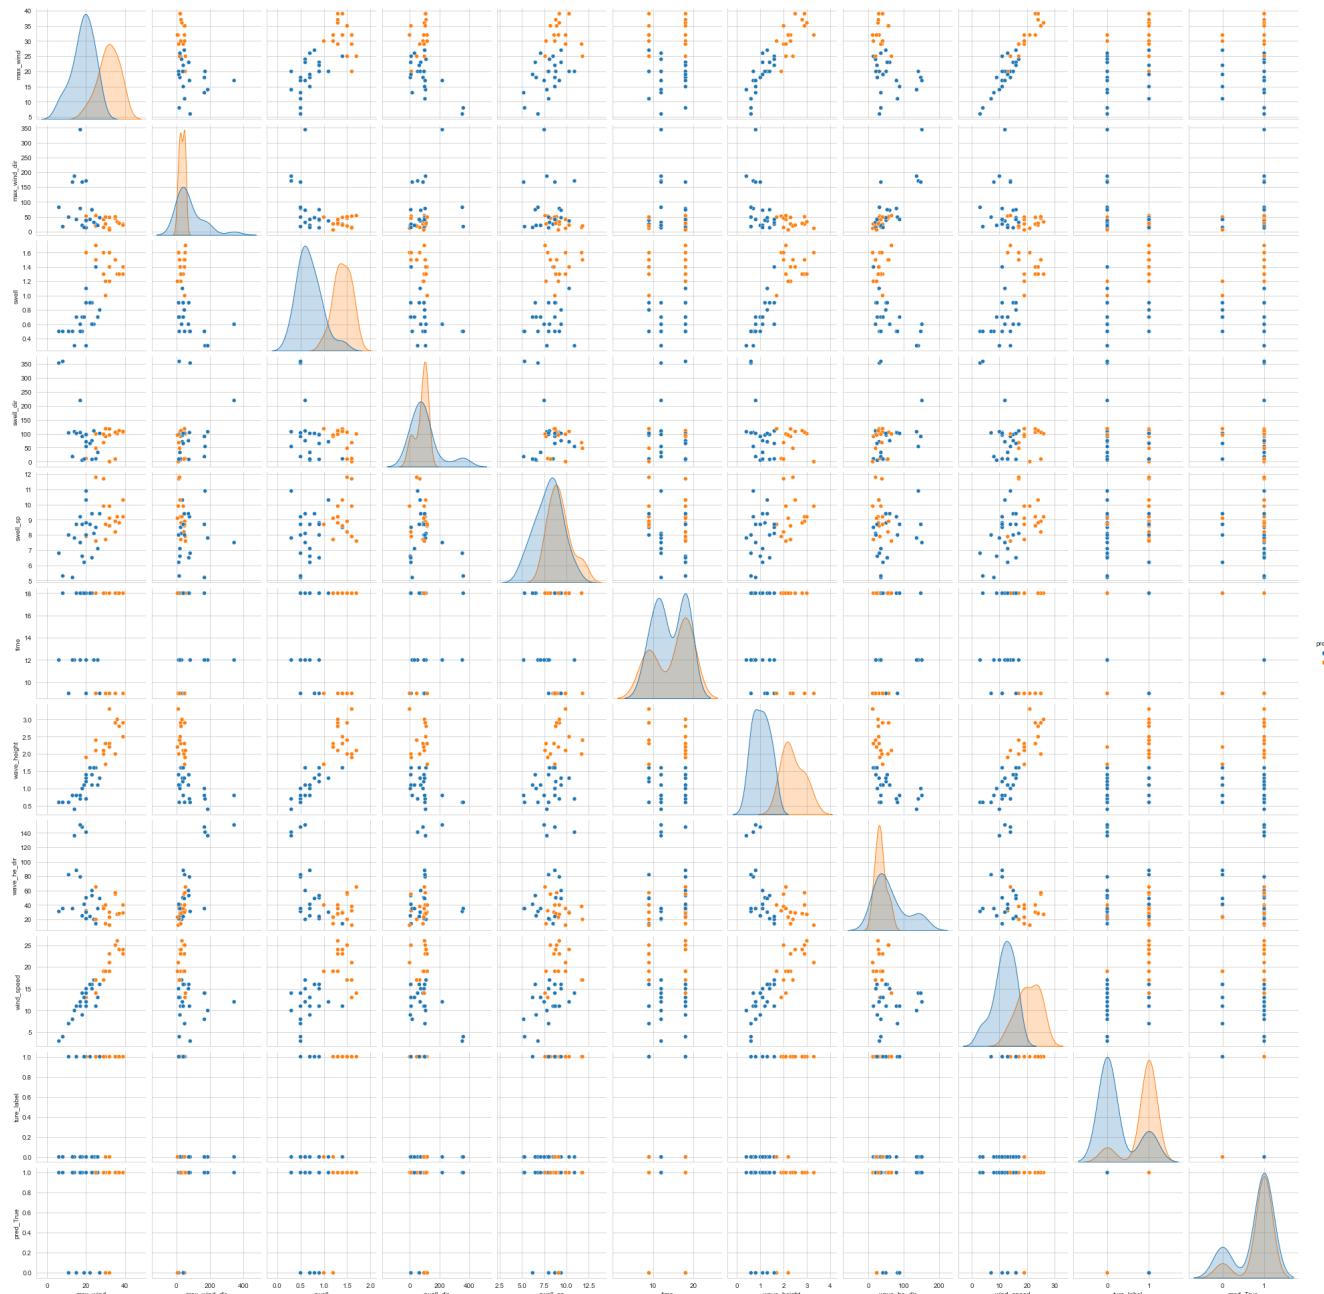


図 4.1: 鳩間島航路 1 日前モデルの予測ラベル

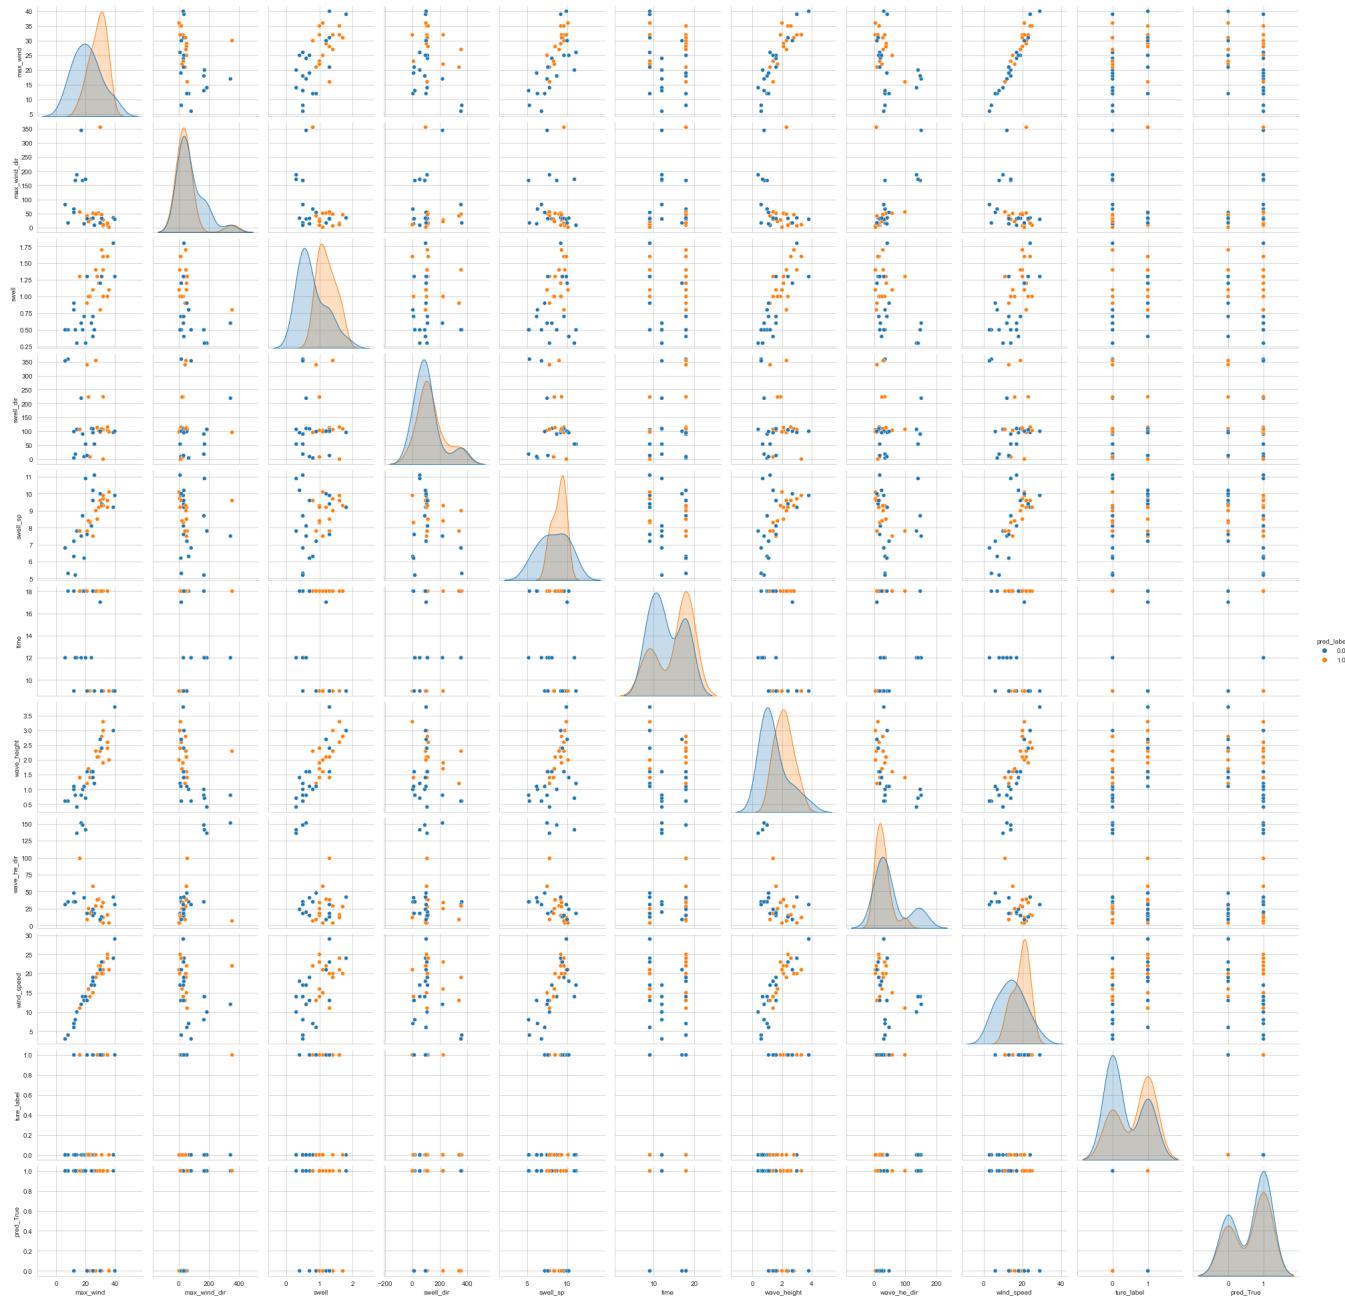


図 4.2: 鳩間島航路 9 日前モデルの予測ラベル

表 4.2 から黒島航路-黒島発当日モデルの結果では全ての評価指標において 1.000 を獲得しており精度がとても良いことがわかる。当日モデルのテストデータの予測結果別に色分けをした散布図 4.3 を確認すると、テストデータにある唯一の欠航データの特徴をしっかりと捉えて予測できたことが確認できる。しかし、表 4.2 の 1 日前モデルの評価結果では正解率 0.987 とよく見えるが F 値が 0.000 となっており欠航データに対する予測が全くできていないことが見て取れる。散布図 4.4 を見てもわかるように全て運航すると予測されている。そこで、1 日前モデルで用いたテストデータの教師ラベルを真値で色分けした散布図 4.5 を見ると欠航データであるオレンジ点が青色の運航データの集団の中に分布してい

ることが確認できる。このことからデータセットの教師データを1日ずらしたモデルの1日前モデルではデータセットをずらすことで欠航という情報を維持できず、運航のデータと変わらないデータになっていることが考えられる。

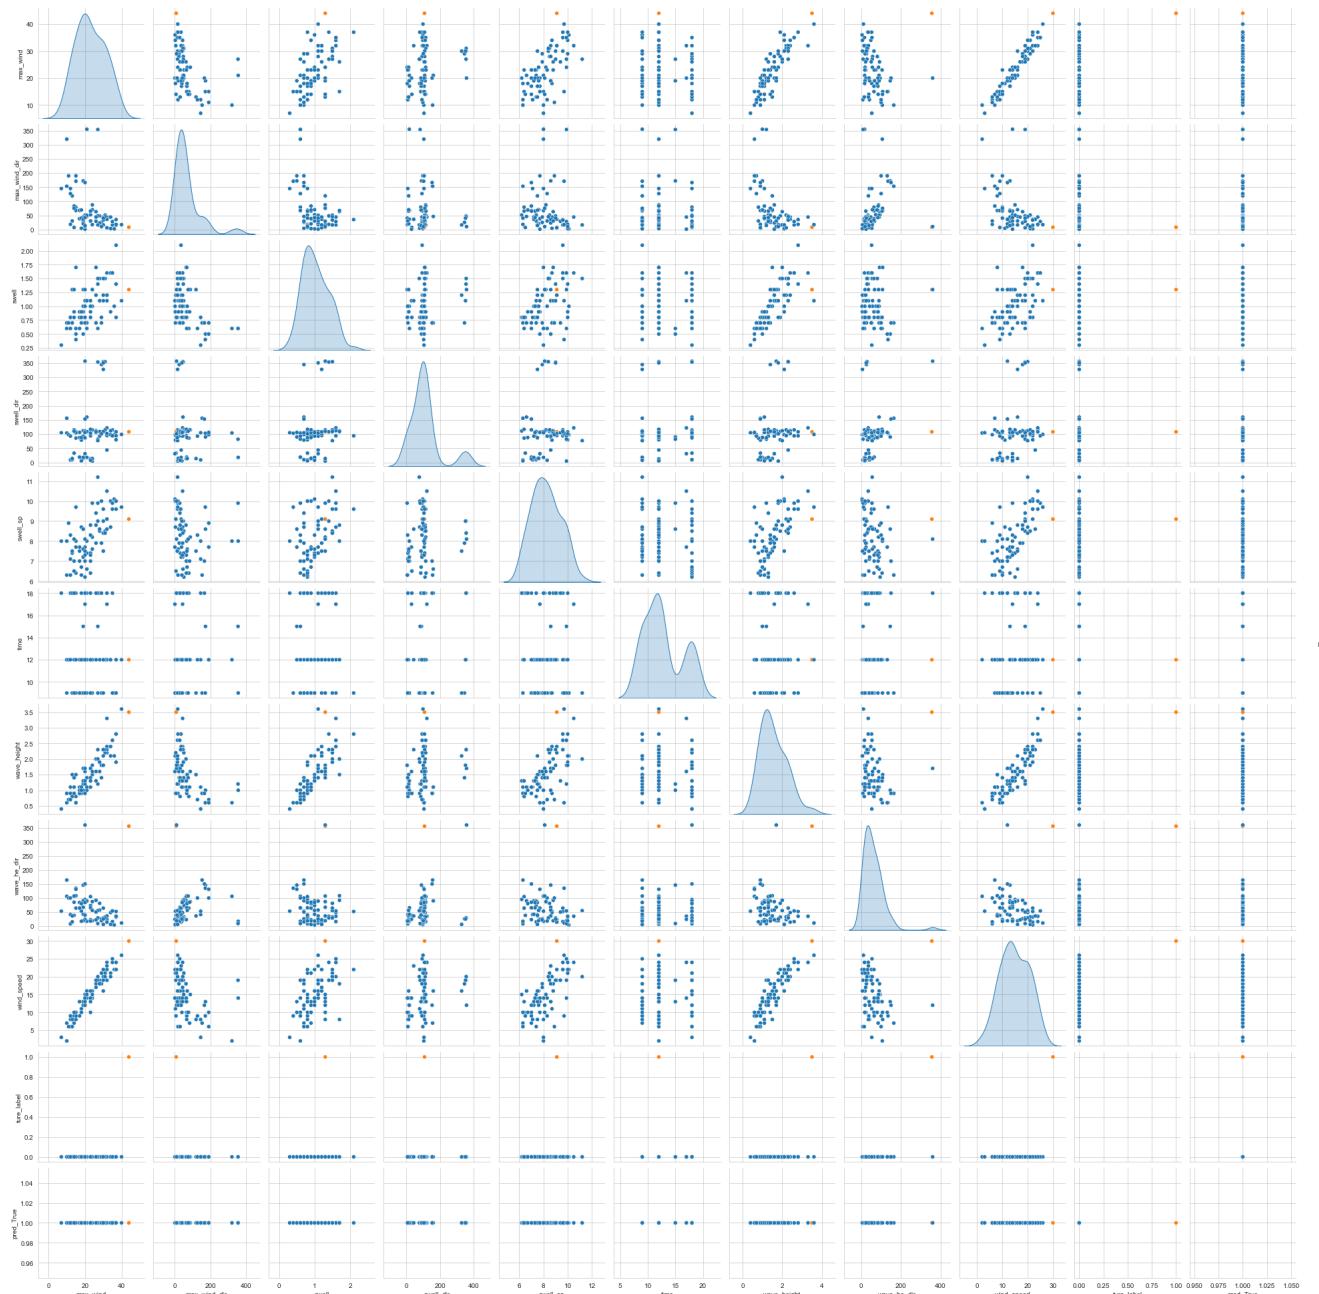


図 4.3: 黒島航路当日モデルの予測ラベル別

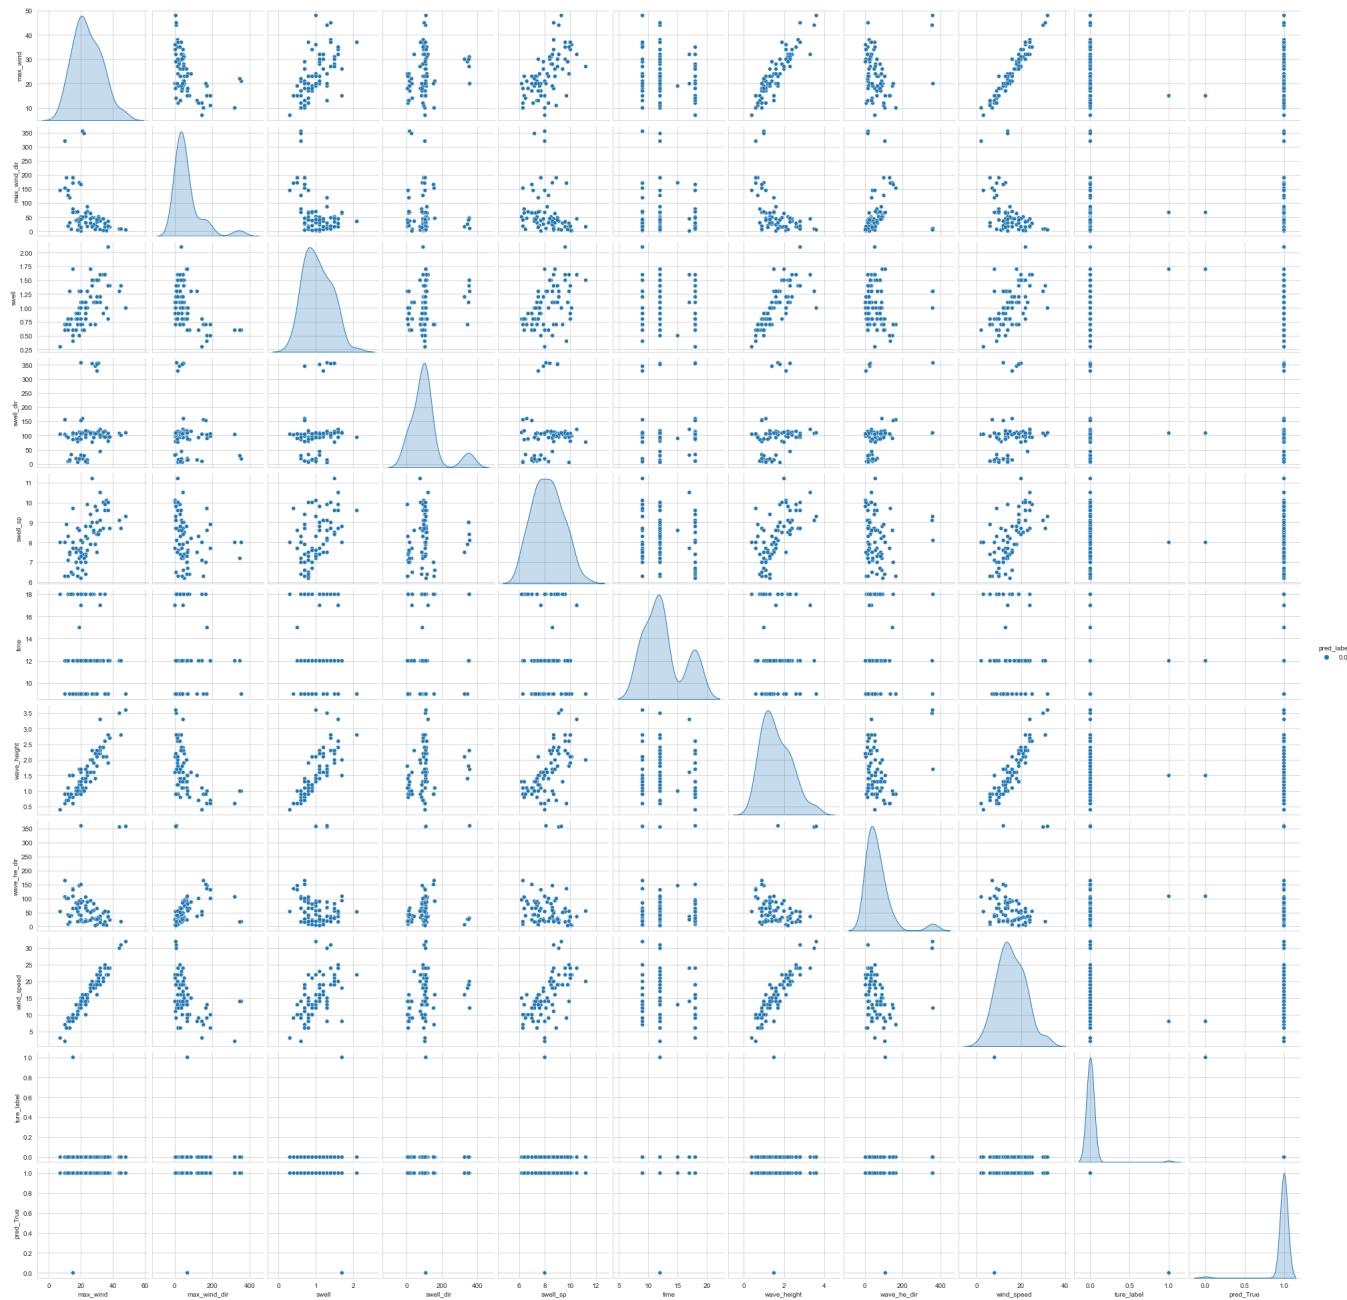


図 4.4: 黒島航路 1 日前モデルの予測ラベル別

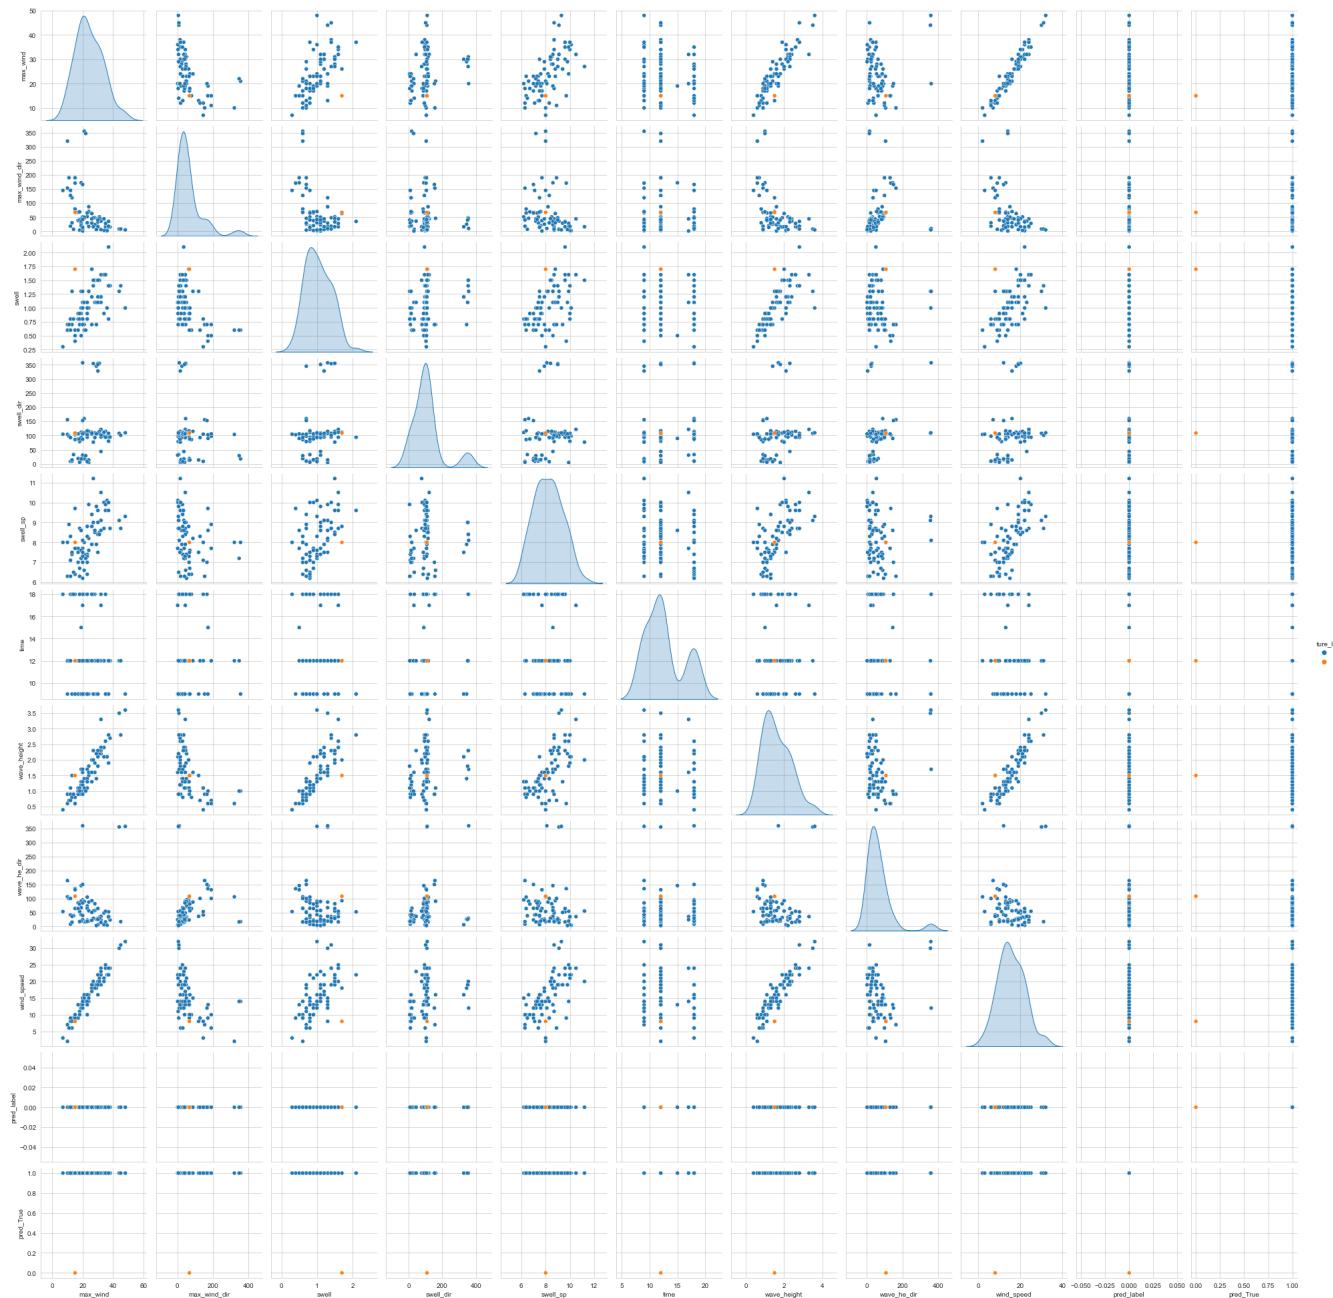


図 4.5: 黒島航路 1 日前モデルの真値ラベル別

4.2.2 画像データの考察

波高レイヤー画像

表 4.3 の波照間航路 1 日前モデルにおいてテストデータ予測結果の混同行列図 4.6 となり、True label の 0 は運航、1 が欠航であり、Predicted label は予想したラベルとなる。TP、FN、FP、TN の画像例として図 4.7、図 4.8、図 4.9、図 4.10 がある。これらの画像からこのモデルは画像全体が青色の場合に運航と判断していることが確認できる。また

その反対に画像全体と画像中心部が赤色の画像を欠航と判断していることが確認できる。FP部分の画像が運航として分類された理由として、図4.9の画像は12月24日13:00に取得された画像だが教師ラベル1日後の12月25日13:00のデータが紐づいているため12月25日13:00の画像を確認すると図4.11となっており波照間航路線のある部分は青色が確認できる。そのため当日は運航していたと考えられ、図4.9の画像の波照間航路線は赤色になっており欠航とモデルは判断したと考えられる。FN部分の画像で運航されると誤分類されているのは図4.8の一枚のみであった。この画像の教師ラベル当日の時間の画像を見ると図4.12となっており、画像は波照間行路線の部分が青色のため当日は運航でき、教師データは運航となっている。しかし、画像大部分が赤色なのでモデルは欠航と予測したと考えられる。

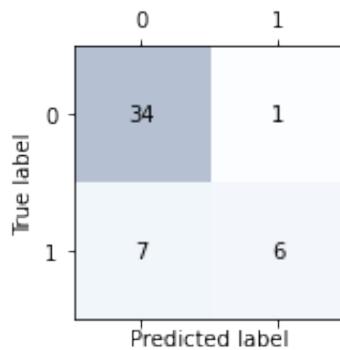


図4.6: 波照間航路1日前モデルの混同行列

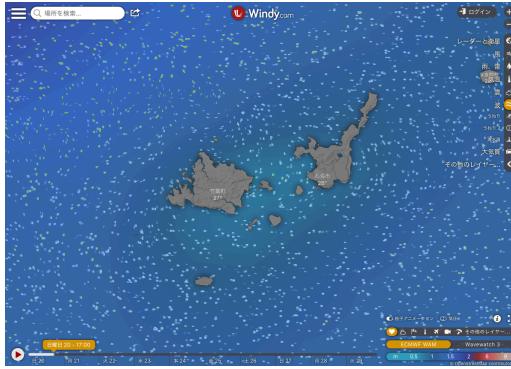


図 4.7: 波照間航路 1 日前モデルの TP 画像例

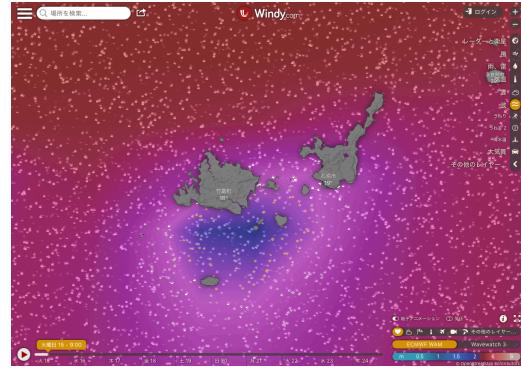


図 4.8: 波照間航路 1 日前モデルの FN 画像

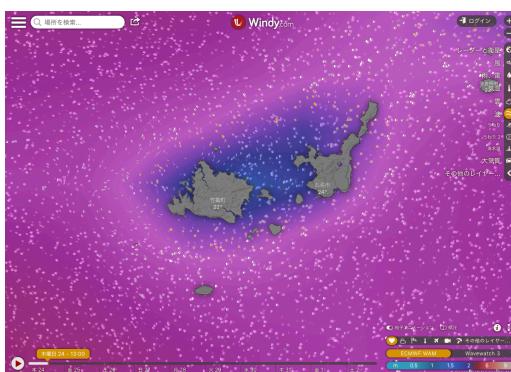


図 4.9: 波照間航路 1 日前モデルの FP 画像例

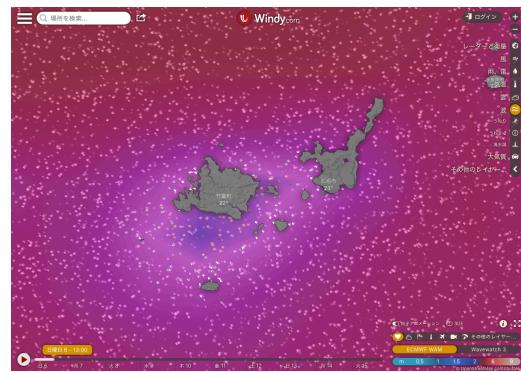


図 4.10: 波照間航路 1 日前モデルの TN 画像例

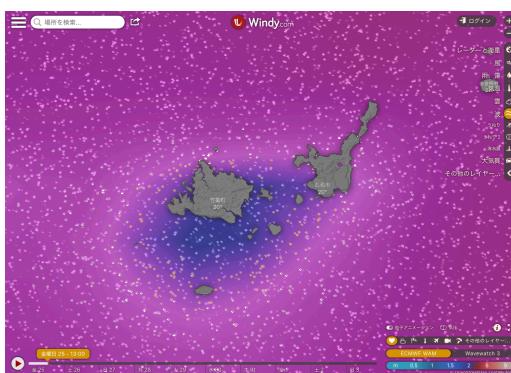


図 4.11: FP 画像 1 日後の教師ラベル当日の画像

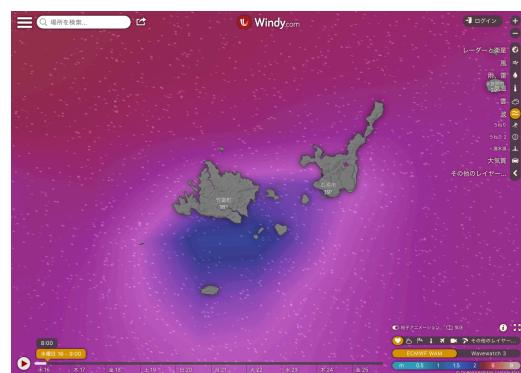


図 4.12: FN 画像 1 日後の教師ラベル当日の画像

表 4.3 の波照間航路 2 日前モデルにおいてテストデータ予測結果の混同行列図 4.13 となり、モデルが運航どのテストデータに対しても運航であると予測していることが確認できる。トレーニングデータを確認すると運航ラベルの付いた画像に図 4.14 のような画像や図 4.15 があることが確認できた。トレーニングデータ中の運航ラベルのついたデータが画像によって一貫性がなく、RGB の値も大きく異なるためにモデルの学習が適切に行えていないことが考えられる。

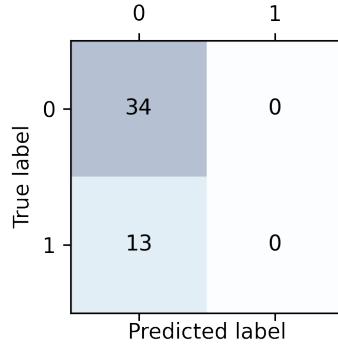


図 4.13: 波照間航路 2 日前モデルの混同行列

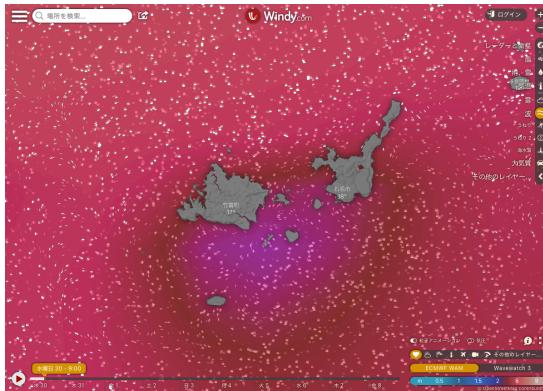


図 4.14: 教師ラベル:運航 1

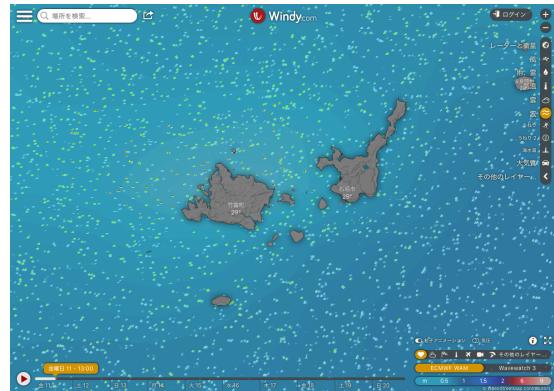


図 4.15: 教師ラベル:運航 2

表 4.4 の波照間航路当日モデルにおいてテストデータ予測結果の混同行列図 4.16 となり、TP、FN、FP、TN の画像例として図 4.17、図 4.18、図 4.19、図 4.20 がある。FN が誤分類された理由としてトレーニングデータ中の画像として図 4.21 があり、図 4.18 と傾向が似ているにもかかわらず教師データが欠航のため、誤分類されたと考えられる。また、傾向が似ているにもかかわらず教師データが異なる理由として、当日の状況が視程が 500m 以下 [8] であったと考えられる。または、風速レイヤーの画像を確認すると風向きが真逆だったため、風向が原因であると考えられる。FP が誤分類された理由として、トレーニングデータ中の画像に図 4.22 が教師データが運航として学習されているために傾向の似ている図 4.19 が誤分類されたと考えられる。

モデルが n 日前の n が増加するたびに F 値が減少していることが確認できる。これは教師データと特徴量のデータを取得した日付が離れることに比例していると考えられる。

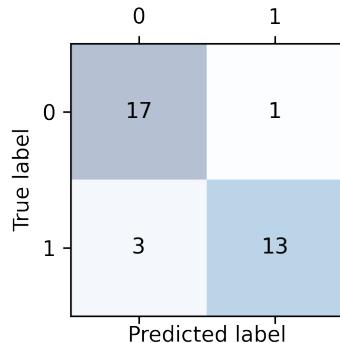


図 4.16: 鳩間島航路当日モデルの混同行列

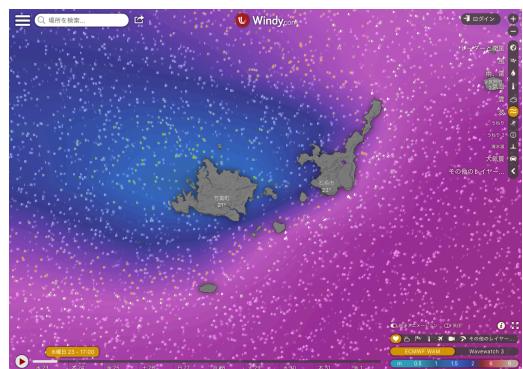
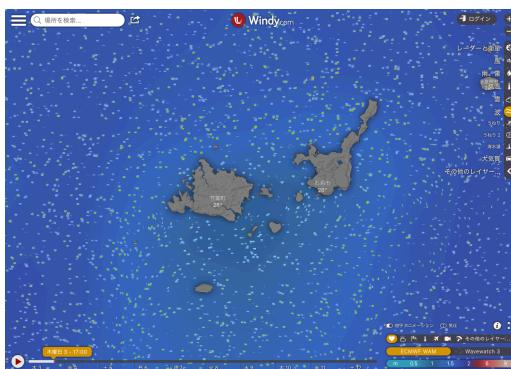


図 4.17: 鳩間島航路当日モデルの TP 画像例 図 4.18: 鳩間島航路当日モデルの FN 画像

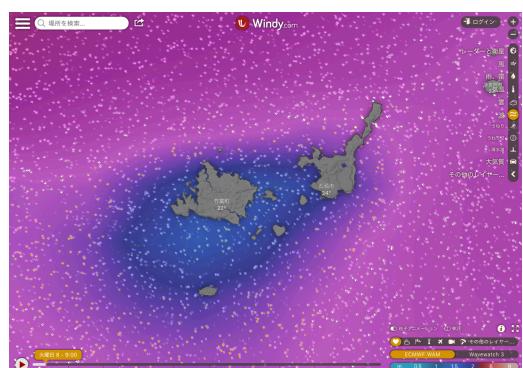
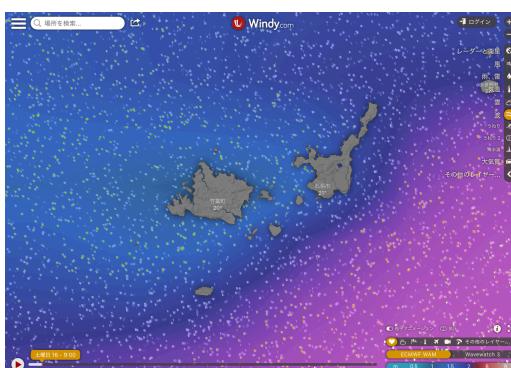


図 4.19: 鳩間島航路当日モデルの FP 画像例 図 4.20: 鳩間島航路当日モデルの TN 画像例

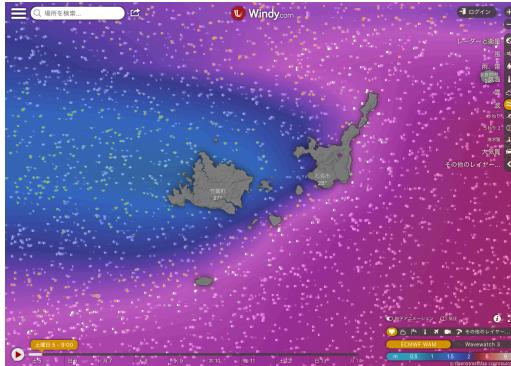


図 4.21: 教師ラベル:欠航

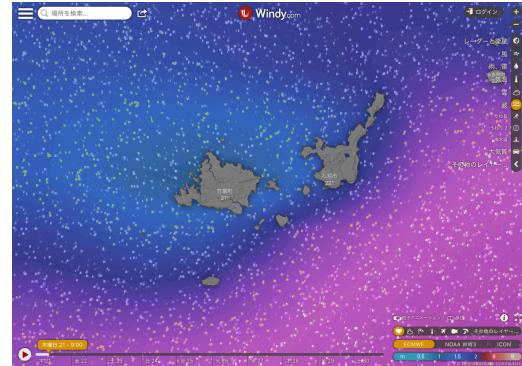


図 4.22: 教師ラベル:運航

表 4.5 の竹富航路では全てのモデルにおいて F 値が 0.000 となっている。これは表 4.3 の 2 日前モデルと同じ理由である。また、竹富航路が欠航データの極端に少ない航路であり、欠航データの学習不足の状態となっていると考えられる。

風速レイヤー画像

表 4.6 の波照間航路 1 日前モデルにおいてテストデータ予測結果の混同行列図 4.23 となる。波高レイヤーの表 4.3 の 1 日前モデル考察と同じように風速レイヤーでも同様の傾向が見られた。

2 日前モデルの混同行列図 4.24 となり、2 日前モデル以降でも波高レイヤーの表 4.3 の 2 日前と同様の傾向が見られたため学習モデルがうまく学習できていないと考えられる。

		0	1
True label	0	33	2
	1	7	6
		Predicted label	

		0	1
True label	0	35	0
	1	13	0
		Predicted label	

図 4.23: 波照間航路 1 日前モデルの混同行列 図 4.24: 波照間航路 2 日前モデルの混同行列

表 4.7 の西表上原航路は表 4.4 と同様の傾向が見られた。またこれらの同様な傾向の見られた航路では 8 日前から F 値の評価が 7 日前と比較して上昇していることが確認できる。8 日間というスパンが教師データと画像をうまく一致するような傾向が本研究で対象とした航路に存在すると考えられる。

表 4.8 の竹富航路でも波高レイヤーと同様に欠航データが極端に少ないと精度が良くならないことが確認できる。

4.3 考察まとめ

数値データでは、散布図により特徴量と予測ラベルの分布を示すことで、モデルの重要視している特徴量を発見できた。予測精度の悪いモデルをでは、特徴量の分布に運航時と欠航時の差異がみられない。これらは教師ラベルと特徴量の取得時間のラグがあることに起因すると考えられる。波高、風速画像ではモデルの出力した予測と入力した画像、トレーニングした画像を比較することで、その航路のモデルにおける画像と教師ラベルの関係性、特徴を解析することができた。性能が極端に低いモデルではトレーニングに使用した画像において、教師ラベルと画像の特徴に規則性がほぼ無いために、画像の特徴を捉えられなかつたと考えられる。風速、波高の画像どちらもモデルに対しての影響が似ていた。これは船舶の欠航が波高の高さ、風速の大きさによって決定するためであると考えられる。また、画像モデルにおいて欠航データが十分にある航路、表4.4と表4.7では、8日前モデルからは評価指標が上昇した。これは本研究で扱った八重山諸島の周辺の気象画像と教師データの関係性において周期性があると考察できる。

これらの考察より欠航予測のための数値データ、画像データの特徴抽出は時系列を考慮したデータが望ましく、つまり予測に周期性を加味できればより高い精度の予測ができるだろう。

第5章 結論

5.1 まとめ

本研究では船舶の運行状況が当日にしか公表されないという問題を機械学習を用い、比較的安易に入手可能な気象状況の値や気象予報図を適用し数日先までを予測する実験を実施した。画像、数値データどちらも9日先までの予測実験を行い、数値用いた予測では特徴量と教師ラベルとの関係を明らかにすることで、学習モデルが重要視している特徴を確認することができた。特徴量の分散をみることで運航データと欠航データとの特徴量の相関を確認し、予測を行うことにおいて重要な特徴量を確認することができた。画像を用いた予測では航路ごとの入力画像を確認することで、どのような画像がモデルに対して影響を与えているかを示した。また、画像分類では鳩間島、西表上原航路において当日から7日前モデルまでは評価指標が減少する傾向にあったが8日前モデルから上昇することを見た。また、これらの考察から数値、画像データを時系列的に扱うことで特徴の変遷を保持することができると考えられる。

5.2 今後の課題

数値と画像どちらのデータも特徴があり、一方だけで無く両方のデータを活用することでデータの特徴生かしたモデル、データセットを構築することで予測精度向上が期待できるのではないかと考えた。

参考文献

- [1] IPCC, de Coninck, H., A. Revi, M. Babiker, P. Bertoldi, M. Buckeridge, A. Cartwright, W. Dong, J. Ford, S. Fuss, J.-C. Hourcade, D. Ley, R. Mechler, P. Newman, A. Revokatova, S. Schultz, L. Steg, and T. Sugiyama, 2018: Strengthening and Implementing the Global Response. In: Global Warming of 1.5 ° C. An IPCC Special Report on the impacts of global warming of 1.5 ° C above pre-industrial levels and related global greenhouse gas emission pathways, in the context of strengthening the global response to the threat of climate change, sustainable development, and efforts to eradicate poverty [MassonDelmotte,V., P. Zhai, H.-O. Pörtner, D. Roberts, J. Skea, P.R. Shukla, A. Pirani, W. Moufouma-Okia, C. Péan, R. Pidcock, S. Connors, J.B.R. Matthews, Y. Chen, X. Zhou, M.I. Gomis, E. Lonnoy, T. Maycock, M. Tignor, and T. Waterfield (eds.)].
- [2] 笹 健児,一寺田 大介,永井 紀彦,河合 弘泰,“船体運動と沿岸波浪に基づくフェリー欠航の判断基準に関する検討”,日本航海学会論文集, 120 号, pp.99-106, 2009.
- [3] Shreya Agrawal, Luke Barrington, Carla Bromberg, John Burge, Cenk Gazen, and Jason Hickey, “Machine learning for precipitation nowcasting from radar images”, arXiv preprint arXiv:1912.12132, 2019.
- [4] Using Machine Learning to ”Now-cast” Precipitation in High Resolution. <https://ai.googleblog.com/2020/01/using-machine-learning-to-nowcast.html>
最終閲覧日:2021/2/1
- [5] ナウファス. <https://www.mlit.go.jp/kowan/nowphas/>
最終閲覧日:2020/9/14
- [6] 安栄観光. <http://www.aneikankou.co.jp/>
最終閲覧日:2021/1/30
- [7] windy.com. <https://www.windy.com/>
最終閲覧日:2021/1/30
- [8] 安栄観光,安全管理規定,旅客船.
<http://www.aneikankou.co.jp/res/pc/pdf/company/legal/anzenkanri5.pdf>
最終閲覧日:2020/9/14

- [9] David J. Fleet and Y. Weiss, “Optical flow estimation”, In Handbook of Mathematical Models in Computer Vision, 2006.
- [10] S. Pulkkinen, D. Nerini, A. A. Pérez Hortal, C. Velasco-Forero, A. Seed, U. Germann, and L. Foresti. Pysteps: an open-source python library for probabilistic precipitation nowcasting (v1.0). *Geoscientific Model Development*, 12(10):4185-4219, 2019.
- [11] Jian Zhang, Kenneth Howard, Carrie Langston, Brian Kaney, Youcun Qi, Lin Tang, Heather Grams, Yadong Wang, Stephen Cocks, Steven Martinaitis, Ami Arthur, Karen Cooper, Jeff Brogden, and David Kitzmiller. “Multi-radar multi-sensor (mrms) quantitative precipitation estimation: Initial operating capabilities”, *Bulletin of the American Meteorological Society*, 97(4):621-638, 2016.
- [12] Stanley G. Benjamin, Stephen S. Weygandt, John M. Brown, Ming Hu, Curtis R. Alexander, Tatiana G. Smirnova, Joseph B. Olson, Eric P. James, David C. Dowell, Georg A. Grell, Haidao Lin, Steven E. Peckham, Tracy Lorraine Smith, William R. Moninger, Jaymes S. Kenyon, and Geoffrey S. Manikin, “A north american hourly assimilation and model forecast cycle: The rapid refresh”. *Monthly Weather Review*, 144(4):1669-1694, 2016.
- [13] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient- based learning applied to document recognition”, *Proceedings of the IEEE*, 86(11):2278-2324, 1998.

謝辞

本研究の遂行、また本論文の作成にあたり、御多忙にも関わらず終始懇切なる御指導と御教授を賜わりました當間愛晃准教授に深く感謝いたします。また一年間共に研究を行い、暖かな気遣いと励ましをもって支えてくれた當間研究室の津波君、松本君、島袋君、具志堅君並びに同研究室先輩方の茂島さん、佐藤さん、伊藤さん、上原さんに感謝致します。

2021年3月
大城紳之亮